

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

ZAVRŠNI RAD br. 2139

**GENERIRANJE PUTANJA MOBILNOG ROBOTA PUTEM
VELIKIH JEZIČNIH MODELA**

Nina Karavanić

Zagreb, lipanj 2025.

Zagreb, 3. ožujka 2025.

ZAVRŠNI ZADATAK br. 2139

Pristupnica: **Nina Karavanić (0036539424)**

Studij: Elektrotehnika i informacijska tehnologija i Računarstvo

Modul: Računarstvo

Mentorica: izv. prof. dr. sc. Tamara Petrović

Zadatak: **Generiranje putanja mobilnog robota putem velikih jezičnih modela**

Opis zadatka:

Veliki jezični modeli (engl. Large Language Models, LLM) imaju sve veću primjenu u robotici, što je motivacija za izradu ovog završnog rada. Najznačajnija primjena LLM-a je u ostvarivanju prirodne interakcije između operatera (čovjeka) te robotskog sustava kroz tekstualne naredbe, što je i motivacija za izradu ovog završnog rada. U radu je potrebno napisati program koji primjenom velikih jezičnih modela generira putanju za mobilno vozilo na temelju specifikacije zadane tekstem. Putanja je niz točaka u prostoru koje vozilo treba posjetiti. Primjerice, korisnik može zadati "Želim putanju u obliku elipse", a program treba generirati točke u 2D prostoru koje čine elipsu. Potrebno je implementirati program koji ostvaruje zadano ponašanje te provesti analizu za različite ulazne specifikacije.

Rok za predaju rada: 23. lipnja 2025.

Zahvaljujem mentorici izv. prof. dr. sc. Tamari Petrović na mentorstvu, stručnom vodstvu te podršci. Također, zahvaljujem asistentici Marijani Peti na pruženoj pomoći i dodatnim pojašnjenjima koji su doprinijeli realizaciji ovog rada.

Sadržaj

1. Uvod	3
2. Opis problema i ideja rješenja	5
3. Pregled korištenih tehnologija	6
3.1. OpenAI	6
3.2. Vizualizacija putanja	7
3.3. Google Drive i Sheets	7
4. Metodologija	8
4.1. Pretpostavke i predradnje	8
4.2. Komunikacija s modelom	8
4.2.1. Izgradnja prompta	8
4.2.2. Poruke s ulogama	9
4.2.3. Korištena system poruka, kontekst	9
4.2.4. Definiranje objekata	11
4.2.5. Mogućnost nastavka razgovora	12
4.3. Prikaz koordinata	13
4.4. Spremanje rezultata	13
4.4.1. Google Drive	14
4.4.2. Google Sheets	14
4.5. Provođenje testiranja	14
4.5.1. Struktura zapisa u Google Sheets dokumentu	15
4.5.2. Nazivi rezultata i povezanost s testovima	16
4.6. Primjeri	17
4.6.1. Primjer 1: Generiranje i modifikacija kruga	17

4.6.2.	Primjer 2	19
4.7.	Analiza rezultata	22
4.7.1.	Analiza prema modifikacijskim zahtjevima	23
4.7.2.	Jednostavni 2D oblici	25
4.7.3.	Jednostavni 3D oblici	32
4.7.4.	Složeni 2D oblici	36
4.7.5.	Složeni 3D oblici	40
4.7.6.	Kompleksni 2D oblici	47
5.	Zaključak	54
	Literatura	55
	Sažetak	56
	Abstract	57

1. Uvod

Robotika je interdisciplinarno područje koje obuhvaća inženjerstvo i računalnu znanost, a bavi se dizajnom, konstrukcijom, upravljanjem i upotrebom robota. U svojoj srži, robotika nastoji razviti sustave koji bi pomogli čovjeku u obavljanju različitih zadataka - bilo kao asistencija, bilo kroz potpunu automatizaciju fizičkih aktivnosti koje je čovjek već savladao. Za razliku od mnogih drugih tehnoloških izuma, robot mora djelovati u istom prostoru kao i čovjek, te se pritom učinkovito kretati i reagirati na okolinu. Sposobnost snalaženja u prostoru, odnosno razumijevanje i interakcija s okolinom, ključna je za učinkovitost robota. Kao što čovjek donosi odluke na temelju informacija iz okoline, tako i robot mora imati sposobnost percepcije, obrade informacija i donošenja zaključaka koji mu omogućuju daljnje djelovanje. U posljednjim desetljećima robotika je postigla velik napredak u mehaničkom dizajnu, upravljačkim sustavima i autonomnoj navigaciji. Međutim, sposobnost robota da provodi procese poput rasuđivanja, planiranja, razumijevanja okoline i komunikacije prirodnim jezikom - koji su kod čovjeka povezani s converanjem - ostala je ograničena i predstavlja izazov u razvoju napredne robotike.

Kombiniranjem robotike s naprednim modelima umjetne inteligencije, kao što je ChatGPT, otvaraju se nove mogućnosti u području inteligentnog donošenja odluka i interakcije s okolinom. Takvi modeli omogućuju robotima naprednije razumijevanje konteksta, bolje planiranje i sposobnost komunikacije na prirodan način. Pomoću umjetne inteligencije, roboti imaju sposobnost prikupljanja, analize i donošenja odluka u stvarnom vremenu, čime se povećava njihova autonomija i učinkovitost u izvršavanju zadataka. Umjetna inteligencija obuhvaća širok spektar sustava koji omogućuju strojevima da oponašaju složene ljudske sposobnosti – poput učenja iz podataka, donošenja predikcija i izvršavanja zadataka bez ljudske intervencije.

Postoje različite vrste robota; autonomni, industrijski, humanoidni, podvodni i mnogi

drugi. Među njima su i dronovi, točnije bespilotne letjelice. Bespilotne letjelice nisu pod izravnom kontrolom pilota, već su upravljanje daljinski (udaljeno) ili djeluju autonomno, prema unaprijed definiranim uputama.

Bespilotnim letjelicama moguće je definirati putanju, odnosno niz koordinata kojima se bespilotna letjelica treba kretati. Tradicionalno se te koordinate zadaju ručno ili pomoću specijaliziranog softvera, što zahtijeva tehničko znanje i precizno planiranje.

Cilj ovog rada je ostvariti zadavanja putanje bespilotnim letjelicama pomoću prirodnog jezika. Za to će se priomijeniti veliki jezični modeli (LLM-ovi), kao što je ChatGPT, koji omogućuju formuliranje putanja u obliku jednostavnih, razumljivih naredbi prirodnim jezikom. Time se otvara mogućnost da korisnici bez tehničkog predznanja upravljaju bespilotnom letjelicom na intuitivan način.

Rad se sastoji od pet poglavlja. U sljedećem poglavlju daje se sažeti prikaz ostvarenih koraka i funkcionalnosti razvijenog sustava, nakon čega slijedi poglavlje u kojem su opisane ključne korištene tehnologije i alati. Treće poglavlje donosi pretpostavke povezane s razvojem komunikacije s modelom te izgradnjom prompta. U istom poglavlju detaljno se objašnjava uloga system poruke, način ostvarivanja mogućnosti nastavka razgovora, mehanizmi za pohranu dobivenih rezultata te način provođenja testiranja. Posljednje poglavlje rada donosi zaključke temeljene na provedenim eksperimentima i opažanjima.

2. Opis problema i ideja rješenja

Glavni je cilj ovog rada omogućiti svakodnevnom korisniku da bespilotnoj letjelici zada putanju korištenjem prirodnog jezika. Primjerice, čovjek može zadati putanju sljedećom naredbom: "Kreiraj putanju oblika piramide".

Kako bi se ostvario zadani cilj, potrebno je osmisliti, razviti i testirati odgovarajući sustav koji objedinjuje mogućnosti umjetne inteligencije i sustava za pohranu podataka.

Testovi predstavljaju skup korisničkih poruka za zadane dvodimenzionalne i trodimenzionalne oblike. Svaki test sadrži isti broj koraka i koristi se za procjenu uspješnosti sustava. Za svaki oblik sustav se testira više puta kako bi se mogla analizirati njegova robusnost i dosljednost. Zbog potrebe za velikim brojem testiranja, izrađen je program koji automatski pokreće testove i pohranjuje njihove rezultate na Google Drive i Google Sheets koristeći prethodno definirani servisni račun.

Repozitorij rada nalazi se na sljedećoj poveznici: [1]

3. Pregled korištenih tehnologija

U ovom poglavlju opisane su ključne tehnologije i alati korišteni za ostvarenje cilja projekta. Proučene su ostvarene funkcionalnosti sa modelom razvijen od strane OpenAI [2], pohranjivanje rezultata na Google Drive i Sheets, te prikaz putanje pomoću matplotlib biblioteke.

3.1. OpenAI

OpenAI, Inc. je američka organizacija za istraživanje umjetne inteligencije (AI) osnovana 2015. godine u Kaliforniji. Cilj joj je razviti sigurnu i korisnu opću umjetnu inteligenciju (AGI). OpenAI je poznat po GPT obitelji velikih jezičnih modela, DALL-E seriji modela za pretvaranje teksta u sliku i modelu za pretvaranje teksta u video pod nazivom Sora. Izdavanje ChatGPT-a u studenom 2022. označilo je početak širokog interesa javnosti za AI tehnologije.[2]

ChatGPT je chatbot temeljen na umjetnoj inteligenciji, razvijen od strane OpenAI-a. Koristi obradu prirodnog jezika za generiranje odgovora koji simulira ljudsku komunikaciju. Osim interaktivnog sučelja, OpenAI omogućuje pristup drugim sličnim modelima putem API-ja, čime se omogućuje integracija istih funkcionalnosti u vlastite aplikacije i sustave. Pomoću OpenAI API-ja moguće je koristiti veliki jezični model za generiranje teksta, koda, matematičkih jednadžbi te strukturiranih JSON podataka, ovisno o postavljenom upitu.

Kod odabira modela, potrebno je uzeti u obzir parametre kao što su razina razumijevanja složenosti zadatka, brzina obrade i cijena korištenja. Modeli koji se ističu od drugih u razumijevanju složenijih zadataka su tipično sporiji i skuplji za korištenje. Manji modeli su brži i jeftiniji, no efikasniji su sa preciznije formuliranim upitima.

Za potrebe ovog projekta korišten je "gpt-4o-2024-08-06", jedan od verzija modela naziva "gpt-4o" (gdje "o" označava "omni" – svestran). Ovaj model prihvaća tekstualne i slikovne ulaze, te vraća tekstualne izlaze, uključujući strukturirani sadržaj.[3]

3.2. Vizualizacija putanja

Za vizualizaciju generiranih koordinata putanje u prostoru korištena je Python biblioteka matplotlib. Ona omogućuje jednostavno prikazivanje 2D i 3D grafova, čime je moguće vizualno provjeriti točnost i izgled generiranih oblika (npr. spirala, krugova, linija i slično) u xyz prostoru.

3.3. Google Drive i Sheets

Pomoću Google Developer platforme, ostvaren je servisni račun. Servisni nam račun omogućuje ovlaštenu pristup Google Driveu i Google Sheetsu. Putem tog računa omogućeno je automatsko spremanje slika putanja te pohrana rezultata testiranja u Google Sheets tablicu. Na taj način se postiže visok stupanj automatizacije, bez potrebe za ručnim unosom rezultata. Podaci se pohranjuju na definiran Google Drive račun, a pristup rezultatima ima vlasnik tog računa ili osobe s kojima je sadržaj podijeljen.

4. Metodologija

4.1. Pretpostavke i predradnje

Uzimajući u obzir ograničenja prostora za letenje i same letjelice, sustav je razvijen uz sljedeće pretpostavke:

- Veličina prostora je unaprijed zadana, točnije, sve dobivene koordinate nalaze se unutar zadanih granica prostora
- Korisnik je upoznat sa sustavom te unosi valjane i razumljive naredbe
- Početna orijentacija letjelice je poznata i pravilno postavljena
- Sustav ne uzima u obzir prepreke u prostoru; prostor je slobodan za letenje

4.2. Komunikacija s modelom

Za uspostavu komunikacije s odabranim modelom, generiran je API ključ te je definirana jasna struktura interakcije između korisnika i modela. Ključne komponente te interakcije uključuju: određivanje uloge poruka, definiranje traženih objekata, oblikovanje učinkovitih upita (prompta) i omogućavanje nastavka razgovora.

System poruka predstavlja važan dio komunikacije s modelom – ona se šalje kao prva poruka u svakom razgovoru i definira pravila ponašanja modela. Na taj način model dosljedno generira odgovore u skladu s ciljevima ovog projekta.

4.2.1. Izgradnja prompta

Kako bi odabrani model pripremili za generiranje sadržaja u skladu sa zahtjevima projekta, primijenjen je pristup poznat kao promptno inženjerstvo; proces oblikovanja učin-

kovitih upita (prompta) za jezične modele.[4]

OpenAI omogućuje više tehnika za konstruiranje takvih uputa. Među najznačajnijima su: korištenje poruka s ulogama i praćenje uputa (*Message roles and instruction following*), korištenje višekratno upotrebljive prompte (*Reusable prompts*), formatiranje poruka pomoću Markdowna i XML-a (*Message formatting with Markdown and XML*), te učenje s nekoliko pokušaja (*Few-shot learning*).[4]

U okviru ovog rada primijenjena je tehnika poruka s ulogama i praćenjem uputa, budući da je ona najprikladnija za strukturirani dijalog i jasno definirano ponašanje modela.

4.2.2. Poruke s ulogama

U komunikaciji s modelom, svaka poruka ima pripisanu ulogu, gdje uloge određuju način na koji model interpretira i prioritizira pojedine poruke. Postoje tri osnovne uloge:

- **system**: upute i pravila zadana od strane programera, najvišeg prioriteta
- **user**: poruke korisnika; upiti ili zahtjevi koji iniciraju generiranje odgovora
- **assistant**: poruke generirane od strane modela kao odgovor na poruke s user ulogom

System poruka ima ključnu ulogu u formiranju ponašanja modela. Šalje se kao prva poruka u nizu te sadrži upute i ograničenja kojih se model treba pridržavati tijekom cijele interakcije s korisnikom. Njezina funkcija je usmjeravanje modela prema željenom tonu, stilu i sadržaju odgovora, čime se smanjuje rizik od neželjenih odstupanja od cilja. U apstraktnom smislu, **system** poruku možemo zamisliti kao funkciju, dok **user** poruku kao argument te funkcije.

4.2.3. Korištena system poruka, kontekst

U okviru ovog rada definirana je poruka s ulogom **system**, koja se prva šalje modelu. Njezina svrha je postaviti jasne smjernice za ponašanje modela prije nego što se započne interakcija s korisničkim porukama (uloge **user**).

Ova početna poruka modelu zadaje ulogu generatora geometrijskih oblika, gdje se traži generiranje skupa koordinata u trodimenzionalnom prostoru koje odgovaraju traženom obliku korisnika.

Uz zadanu ulogu, modelu su definirana sljedeća textitopća pravila te *Stablo odlučivanja*:

```
"You are a geometric-shape generator; Generate a set of three-
    dimensional coordinates that form the requested shape."

"General rules:"
"1. Specify if the shape is two-dimensional or three-dimensional
    ."
"1.1 If the shape is two-dimensional, orient them parallel to
    the xz-plane (unless specified otherwise)."
"1.2 If the shape is three-dimensional, ensure the base is
    parallel to the xy-plane (unless specified otherwise)."
"2. If the shape is continuous, closed (i.e., has no distinct
    endpoints, like a circle or a polygon), ensure that the path
    is closed by making the last coordinate the same as the first
    coordinate."
"4. For shapes that do not belong to a set of elementary (or
    fundamental) geometric shapes (fundamental geometric shapes
    are for example circle, triangle, rectangle, circle) we will
    call 'complex shapes'."
"4.1 Example of complex shapes: star, heart, swirl, cross, arrow
    ."
"4.2 For complex shapes, provide a detailed set of coordinates
    that capture the shape's features (for example, petals or
    curves) rather than a basic outline."

"5. Here's an example request: 'Generate coordinates for a 2D
```

```

    triangle, base parallel to the xz-plane'."
"6. You can only use one rule from the 'Decision tree'. You must
    specify which rule you used in response!"

"Decision tree:"
"1. Try to identify or derive a suitable mathematical equation (
    parametric, polar, implicit, or piecewise) whose graph
    represents that shape."
"1.2 If found, sample enough points from that equation to
    produce a smooth, recognizable outline."

"2. Find analytic decomposition (lines, arcs, B ziers) and
    sample it."
"2.1 For complex shapes, make sure they have their curves and
    points (for example, heart has symmetrical curves and point at
    a bottom)."
"3. If first and second rule were both not applicable, give your
    own idea and then return coordinates from that idea"

```

4.2.4. Definiranje objekata

Model za svaki upit korisnika vraća skup koordinata te tekstualni odgovor. Kako bi se ostvario takav struktuirani izlaz modela, definirani su Python objekti korištenjem biblioteke pydantic.

Definirana su dva osnovna modela:

- `Coordinate` – predstavlja jednu točku u trodimenzionalnom prostoru, s atributima `xCoord`, `yCoord` i `zCoord` tipa `float`.
- `CoordinatesResponse` – objekt koji predstavlja odgovor modela. Sadrži listu objekata tipa `Coordinate` pod nazivom `pathCoord` te završni tekstualni odgovor modela pod nazivom `final_answer`.

4.2.5. Mogućnost nastavka razgovora

Jedna od ključnih funkcionalnosti ChatGPT modela dostupnog preko web sučelja je mogućnost nastavka razgovora. Sve prethodno razmijenjene poruke su sačuvane te čine kontekst koji model koristi pri generiranju novih odgovora. Međutim, prilikom korištenja modela putem API-ja, ta funkcionalnost nije automatski dostupna – prethodni kontekst potrebno je ručno upravljati. Svaki novi zahtjev putem API-ja mora sadržavati i sve prethodne poruke kako bi model zadržao kontinuitet u interakciji.

Kako bi se ostvarila mogućnost nastavka razgovora i omogućilo postupno modifikiranje prethodno generiranih pitanja, potrebno je sačuvati sve do tada razmijenjene poruke. Poruke se dodavaju i spremaju u JSON datoteku. Sa svakom novom porukom korisnika, osim nove poruke šalje se i cijeli sadržaj navedene JSON datoteke. Ovim načinom novi generirani tekst od strane modela ujedno će ovisiti i o prijašnjem razgovoru.

JSON ("JavaScript Object Notation") datoteka je koja se koristi za razmjenu podataka. To je tekstualni i strukturirani format koji je čitljiv ljudima i strojevima. [5]

U ovom radu, ta se datoteka naziva `conversation.json`. U navedenoj se datoteci poruke spremaju u obliku liste objekata, gdje svaki objekt sadrži ulogu (*system*, *user*, *assistant*) i sadržaj poruke.

Tijek rada:

1. U datoteku se sprema početna *system* poruka s pravilima
2. Nakon korisničkog unosa, nova poruka se dodaje s ulogom *user* u datoteku `conversation.json`
3. Sadržaj datoteke `conversation.json` šalje se modelu
4. Nakon što model generira odgovor i skup koordinata, one se spremaju kao nova poruka s ulogom *assistant*

Korištenjem navedene strukture ostvarene su sljedeće prednosti:

- Model ne reagira samo na posljednju poruku korisnika, već oblikuje odgovor na temelju cijelog prethodnog konteksta.

- Korisnik može tražiti generiranje novog dvodimenzionalnog ili trodimenzionalnog oblika, ali i modificirati prethodno generirani (npr. promjena radijusa, skaliranje površine, rotacija).
- Omogućena je iterativna interakcija – svaki novi unos nadograđuje postojeću komunikaciju, čime se simulira prirodan dijalog.

4.3. Prikaz koordinata

Za vizualizaciju generiranih koordinata koristi se Python biblioteka `matplotlib`, uz dodatak `mpl_toolkits.mplot3d` koji omogućuje trodimenzionalno crtanje. Svaki skup koordinata prikazuje se kao 3D slika u obliku povezanih točaka koje predstavljaju putanju u prostoru.

Generira se prikaz iz tri različite perspektive:

- standardni 3D pogled (iz kuta)
- pogled odozgo (XY ravnina)
- pogled s bočne strane (YZ ravnina)

Sve tri projekcije prikazuju se unutar jedne slike.

Generirana slika automatski se sprema u direktorij `convImages` pod imenom `imgN.png`, gdje `N` označava redni broj vizualizacije. Prilikom spremanja slike na Google Drive, ime slike se mijenja prema pravilima opisanima u odjeljku 4.5.2.

4.4. Spremanje rezultata

Kako bi se rezultati generirani tijekom rada sustava mogli trajno pohraniti i kasnije analizirati, razvijen je dodatan program za automatsko spremanje slika i poruka u Google Drive i Google Sheets. Time se omogućuje strukturirano praćenje testova, rezultata i komunikacije s modelom, bez potrebe za ručnim unosom podataka.

4.4.1. Google Drive

Za svaki novi skup koordinata koji model generira izrađuje se vizualizacija u obliku slike koja prikazuje dobiveni skup koordinata u trodimenzionalnom prostoru. Navedene se slike automatski spremaju u Google Drive, čime se omogućuje njihov jednostavan pristup, pregledavanje i dugoročna pohrana rezultata. Za integraciju s Google Driveom korišten je *Google Drive API*, koji omogućuje razvoj aplikacija s mogućnošću upravljanja datotekama na oblaku.[6]

Pristup Google Driveu nije omogućen svima, već isključivo putem servisnog računa. Servisni račun je posebna vrsta računa u sklopu Google Cloud Platforme, namijenjena aplikacijama i automatiziranim procesima. Pomoću odgovarajućih vjerodajnica (u ovom radu, one se nalaze u JSON datoteci naziva `credentials.json`), aplikacija dobiva ovlaštenje za pristup i spremanje datoteka u unaprijed definirani direktorij na Driveu.

4.4.2. Google Sheets

Uz slike koordinata, sve poruke razmijenjene između korisnika i modela — uključujući korisničke zahtjeve, odgovore modela i poveznice pripadajuće slike — automatski se pohranjuju u Google Sheets dokument. Time se omogućuje sustavno praćenje i naknadna analiza ponašanja modela kroz različite testne scenarije. Za interakciju s tablicama korišten je *Google Sheets API*, RESTful sučelje koji omogućuje programatski pristup podacima u tablicama — uključujući čitanje, pisanje, uređivanje i organizaciju sadržaja.[7] Kao i u slučaju Google Drivea, pristup je omogućen putem autentifikacije servisnim računom, čime se omogućuje potpuna automatizirana pohrana podataka bez potrebe za ručnim unosom od strane korisnika.

4.5. Provođenje testiranja

Testiranje se provodi nad unaprijed definiranim skupom dvodimenzionalnih i trodimenzionalnih geometrijskih oblika, razvrstanih prema razini složenosti:

- **Jednostavni 2D oblici:** krug, trokut, peterokut
- **Jednostavni 3D oblici:** kocka, piramida, šesterokutna prizma

- **Složeni 2D oblici:** oval, strelica, zvijezda
- **Složeni 3D oblici:** stožac, oktaedar, cilindar
- **Kompleksni 2D oblici:** sinusna funkcija, mladi mjesec, cvijet

Svaki test sastoji se od pet uzastopnih pitanja. Prvo pitanje odnosi se na generiranje osnovnog oblika, dok se preostala četiri odnose na modifikaciju tog oblika. Ovim pristupom testira se sposobnost modela ne samo da generira traženi geometrijski oblik, već i da ga prilagođava dodatnim zahtjevima. **Modifikacijski zahtjevi** mogu se svrstati u sljedećih nekoliko kategorija:

- Povećanje/smanjenje radijusa
- Povećanje/smanjenje broja koordinata
- Vraćanje na prethodnu verziju
- Povećanje/smanjenje visine
- Rotacija za 90 stupnjeva u određenom smjeru
- Povećanje/smanjenje samo jedne strane tako da je duža od svih ostalih
- Povećanje/smanjenje određene površine ili baze
- Ogledanje (npr. "okreni naopako" ili "zrcali slijeva na desno")
- Orijentacija prema zadanoj osi ili ravnini (npr. paralelno s XY-ravninom)

Ukupno se provodi 15 testova, po jedan za svaki od definiranih oblika. Svaki test se izvodi 20 puta, kako bi se procijenila dosljednost i robusnost modela. Rezultati svakog pokretanja automatski se spremaju u Google Sheets tablicu.

4.5.1. Struktura zapisa u Google Sheets dokumentu

Google Sheets tablica koristi se za sustavno bilježenje svakog testa, a sastoji se od šest stupaca:

Stupac	Sadržaj
A	Naziv oblika
B	Broj iteracije (1 do 20)
C	Redni broj pitanja unutar testa (1 do 5)
D	Tekst upita (npr. "Povećaj radijus")
E	Odgovor modela (tekstualni opis i/ili generirane koordinate)
F	Poveznica na sliku rezultata (spremljenu na Google Drive)
G	Ocjena

Tablica 4.1. Značenje stupaca u tablici s rezultatima testiranja

	A	B	C	D	E	F	G
279	Cube	10	3	Reduce the Z-height	The Z-height for the coordinates has been reduced by half.	https://drive.google.com/file/d/1nXc1Y22sVstheD_koFN0bmkAQFp...	Uspjesno
280	Cube	10	4	Lengthen only one side so it is longer than the others	The length of the side in the x-direction has been increased	https://drive.google.com/file/d/1PhYNoQle8JzKlQa5GY6ilxk7JnYg...	Uspjesno
281	Cube	11	1	Generate coordinates for a 3D cube	Using a cube, we identified the vertices of the cube and con	https://drive.google.com/file/d/1J3sh34MvD7-PHLMuAkujAATJG...	Uspjesno
282	Cube	11	2	Rotate 90 degrees about the X-axis	After rotating the cube 90 degrees about the X-axis, the y a	https://drive.google.com/file/d/1jeM4Zm4rwtUuXWde82X7S4IPWj...	Uspjesno
283	Cube	11	3	Reduce the Z-height	The Z-height of the cube has been reduced by halving the z	https://drive.google.com/file/d/1v6UmfWVGKxmNcSJW-bRcKl9...	Uspjesno
284	Cube	11	4	Lengthen only one side so it is longer than the others	The length of the side along the x-axis has been increased	https://drive.google.com/file/d/1cQ9Q7ss6QULnqdkymc0FV9_ukf...	Uspjesno
285	Cube	12	1	Generate coordinates for a 3D cube	These coordinates form the path around the edges of a cub	https://drive.google.com/file/d/1bTWqo7ZsZyC30V0ah2vuxO2Lf...	Uspjesno
286	Cube	12	2	Rotate 90 degrees about the X-axis	A 90-degree rotation about the X-axis swaps the Y and Z co	https://drive.google.com/file/d/1D4cH6ApDby_cZMFy4u0LJ0koNB...	Uspjesno
287	Cube	12	3	Reduce the Z-height	A reduced Z-height implies the cube is squashed along the	https://drive.google.com/file/d/1cao8tFyBUklexCbnzS1v-GpTq2h...	Uspjesno
288	Cube	12	4	Lengthen only one side so it is longer than the others	One side of the rectangular prism has been lengthened to 2	https://drive.google.com/file/d/1wUjZC050cQ9fOI7mW34VbYdE2f...	Uspjesno
289	Cube	13	1	Generate coordinates for a 3D cube	I used Decision Tree Rule 3 to form a cube by manually def	https://drive.google.com/file/d/1qk_4DC_UGFcuFLCHQYmYtHIS...	Uspjesno
290	Cube	13	2	Rotate 90 degrees about the X-axis	The cube was rotated 90 degrees about the X-axis by trans	https://drive.google.com/file/d/1x7FFp49RcGgkQJCBj2zC6dR89...	Uspjesno
291	Cube	13	3	Reduce the Z-height	The Z-height has been reduced from 1.0 to 0.5 for each poi	https://drive.google.com/file/d/1ECDbvyPvAhniDrSWd01LV5Wgh...	Uspjesno
292	Cube	13	4	Lengthen only one side so it is longer than the others	One side (x-axis dimension) was lengthened from 1.0 to 2.0	https://drive.google.com/file/d/1ve5NblcP6Gns-Fm36-Aee0AJGvEi...	Uspjesno
293	Cube	14	1	Generate coordinates for a 3D cube	Generated coordinates for a 3D cube, listing each vertex an	https://drive.google.com/file/d/18A4CmpnCOKGmcVFh47XiEwtEz...	Prosječno
294	Cube	14	2	Rotate 90 degrees about the X-axis	The coordinates have been rotated 90 degrees about the X	https://drive.google.com/file/d/1g8W3Qe-hRYOyjpV5Nh-YcmGLT...	Neuspjesno
295	Cube	14	3	Reduce the Z-height	Reduced the Z-height by halving the original Z dimension. h	https://drive.google.com/file/d/1-BcmzQNYRAktgGtnuZq7-5eWlh3...	Uspjesno
296	Cube	14	4	Lengthen only one side so it is longer than the others	The X-length has been increased by 0.5 units.	https://drive.google.com/file/d/1MndMie-jd0itPT2Sw2QKvtofs7Jh...	Uspjesno
297	Cube	15	1	Generate coordinates for a 3D cube	Coordinates for a 3D cube, ensuring it is closed, with the ba	https://drive.google.com/file/d/1nq_UWUPhByw0x2pmXrCi3yTizaY...	Prosječno
298	Cube	15	2	Rotate 90 degrees about the X-axis	Rotated the cube 90 degrees about the X-axis by transform	https://drive.google.com/file/d/1ksSopvSZuZ253uRQoczZMav_PFT...	Uspjesno
299	Cube	15	3	Reduce the Z-height	Reduced the Z-height of the cube by halving the original z-c	https://drive.google.com/file/d/1I2JpscdWtT6FMqmc8wSCNndLkix...	Uspjesno
300	Cube	15	4	Lengthen only one side so it is longer than the others	Lengthened the x-direction by increasing the x-coordinate tr	https://drive.google.com/file/d/1cOXB_A604OuM2qB2c3CUnCSJ...	Uspjesno

Slika 4.1. Prikaz dijela Google Sheets tablice

4.5.2. Nazivi rezultata i povezanost s testovima

Svaki test moguće je jedinstveno identificirati prema nazivu oblika koji test ispituje, te broju iteracije. Na sličan način imenuju se i slike spremljene u Google Drive, čime se osigurava dosljedno povezivanje između poruka, rezultata i slika. Naziv svake slike generira se prema uzorku:

[Oblik]_Iter[broj iteracije]_Q[broj pitanja]

Primjerice, za test koji se odnosi na oblik kruga, četvrtu iteraciju i drugo pitanje unutar testa, generirani naziv slike bit će Circle_Iter4_Q2.

4.6. Primjeri

4.6.1. Primjer 1: Generiranje i modifikacija kruga

Korisničke upute

U ovom scenariju testira se generiranje putanje za oblik kruga, koji pripada skupini jednostavnih dvodimenzionalnih oblika kako je prethodno prikazano u odjeljku 4.5.

Nakon pokretanja programa, na ekranu se ispisuje sljedeće:

Please input shape:

Korisnik unosi sljedeći upit:


Generate coordinates for a 2D circle

Model analizira upit i prepoznaje da je traženi oblik *circle* (*krug*). Na temelju toga generira odgovor koji uključuje opis postupka i skup koordinata. Tekstualni odgovor ispisuje se na zaslonu, dok se vizualizacija generiranih koordinata prikazuje putem slike:

To generate the coordinates of a 2D circle, I used the parametric equation for a circle and calculated points with every 18 degrees around the circle to make it well-defined:

$$x(t) = R * \cos(t) \quad y(t) = R * \sin(t)$$

Where R (radius) = 5 and t varies from 0 to 360 degrees. I sampled points at increments of 18 degrees to create a smooth outline.



Slika 4.2. Vizualizacija dobivenih koordinata za krug

Mogućnost modifikacije

Nakon prikaza rezultata, korisniku se nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik odlučuje modificirati oblik i upisuje sljedeći zahtjev:

Make the radius smaller

Model obrađuje zahtjev i generira novu verziju oblika, skalirajući radijus. Odgovor modela glasi:

The radius was reduced to 3 and the points were recalculated using the parametric equation of a circle with $R = 3$.



Slika 4.3. Modifikacija kruga – smanjenje radijusa

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik zatim unosi sljedeći zahtjev:

Reduce the number of coordinates

Model odgovara:

The number of coordinates was reduced by sampling at quadrants angles (90, 180, 270, 360 degrees) around the circle.



Slika 4.4. Modifikacija kruga – smanjenje broja koordinata

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:

Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik prekida daljnju modifikaciju upisom naredbe:

quit

U ovom scenariju model uspješno generira krug te ispravno smanjuje njegov radijus. Prilikom zahtjeva za smanjenjem broja koordinata, model ih reducira na svega četiri, što možda nije očekivano, budući da takav broj nije dovoljan za očuvanje prepoznatljivog oblika. Ova situacija ukazuje na potrebu preciznijeg i detaljnijeg prompta pri postavljanju zahtjeva za smanjenje broja točaka.

4.6.2. Primjer 2

U ovom scenariju tražiti će se dobivanje putanje oblika stošca, koji pripada skupini složenih trodimenzionalnih oblika, kako je prethodno prikazano u odjeljku 4.5.

Nakon pokretanja programa, na ekranu se ispisuje sljedeće:

Please input shape:


Korisnik unosi sljedeći upit:

Generate coordinates for a 3D cone with circle as a base

Model analizira upit i prepoznaje da je traženi oblik *cone* (stožac). Na temelju toga generira odgovor koji uključuje opis postupka i skup koordinata. Tekstualni odgovor

ispisuje se na zaslonu, dok se vizualizacija generiranih koordinata prikazuje putem slike:

The cone is a 3D shape with a circular base parallel to the xy-plane. I used Decision Tree Rule 1. I first approximated the base of the cone with a circle made of points, the apex of the cone is placed on the z-axis. The following coordinates form a cone with a unit circle as the base and with its apex at (0, 0, 1), centered at the origin.



Slika 4.5. Vizualizacija dobivenih koordinata za stožac

Mogućnost modifikacije

Nakon prikaza rezultata, korisniku se nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik odlučuje modificirati oblik i upisuje sljedeći zahtjev:

Make the radius of base smaller

Model obrađuje zahtjev i generira novu verziju oblika, skalirajući radijus baze. Odgovor modela glasi:

A 3D cone with a smaller base radius of 0.5 and height of 1, with the circular base as a series of points and apex at (0, 0, 1).



Slika 4.6. Modifikacija stošca - smanjenje radijusa

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik zatim unosi sljedeći zahtjev:

Reduce the height

Model odgovara:

A 3D cone with a base radius of 0.5 and reduced height of 0.5, with the apex at (0, 0, 0.5).



Slika 4.7. Modifikacija stošca - smanjenje visine

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:

Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik prekida daljnju modifikaciju upisom naredbe:

quit

Kako bi se dobio što točniji željeni oblik, potrebno je formulirati detaljniji upit. U ovom scenariju, upit je precizniji u odnosu na prethodni te uključuje specifikaciju da baza stošca bude oblik kruga — što je ključno, budući da u suprotnom model može generirati stožac s bazom drugačijeg oblika, što se ranije pokazalo kao mogući ishod. Model je uspješno smanjio radijus baze i visinu stošca, pritom zadržavajući ostale značajke oblika nepromijenjenima.

Dobivena putanja

Dobivena putanja može se koristiti kao ulaz za upravljanje robotskim sustavima, osobito bespilotnim letjelicama (dronovima). Praćenjem zadanih koordinata u prostoru, letjelica može izvesti gibanje koje ocrtava zadani geometrijski oblik.

4.7. Analiza rezultata

U skladu s prikazanim u odjeljku 4.5., testiranje je obuhvatilo ukupno 15 testova, gdje je svaki test bio usmjeren na jedan od prethodno predstavljenih oblika. Svaki test ponavljen je 20 puta, čime je generiran relevantan skup podataka za analizu. Tablica s rezultatima, pohranjena u Google Sheets dokumentu, sadrži dodatan stupac za ocjenjivanje svakog odgovora. Za svako pojedino pitanje unutar testa dodjeljuje se jedna od tri ocjene, ovisno o uspješnosti odgovora generiranog od strane modela. Ocjene su definirane na sljedeći način:

Tablica 4.2. Kriterij za ocjenjivanje uspješnosti generirane putanje

Ocjena	Opis
Uspješno	Dobivena putanja zadovoljava sve zahtjeve korisnika; oblik koji putanja predstavlja je jasno prepoznatljiv i odgovara opisu iz korisničkog upita
Prosječno	Dobivena putanja djelomično zadovoljava zahtjeve korisnika; iz odgovora modela je ostvarena jasna i dobra ideja, ali generirana putanja ne predstavlja tu ideju
Neuspješno	Dobivena putanja ne zadovoljava zahtjeve korisnika; geometrijski prikaz putanje je nejasan; ideja izvedbe nije prepoznatljiva

Podsjetimo, za svaki korisnički upit model vraća dva izlaza: putanju u obliku skupa trodimenzionalnih koordinata te tekstualni odgovor kojim pojašnjava način generiranja te putanje, kako je prethodno prikazano u odjeljku 4.2.4.

Ako promotrimo sve provedene testove, dobiveni rezultati pokazuju sljedeću raspodjelu ocjena:


Ocjena	Postotak
Uspješno	78.67%
Prosječno	7%
Neuspješno	14.33%

Tablica 4.3. Zastupljenost svake ocjene u svim testovima

Slijedi detaljnija analiza rezultata prema vrstama oblika i kategorijama zahtjeva.

4.7.1. Analiza prema modifikacijskim zahtjevima

Gledajući sve testove zajedno, svaki se modifikacijski upit pojavio jednak broj puta. Na slici 4.8. je prikazan omjer ocjena *uspješno*, *prosječno* i *neuspješno* za svaki od devet modifikacijskih upita:



Slika 4.8. Omjer ocjena za svaki modifikacijski upit

Pojedini upiti pokazali su iznimno visoku razinu uspješnosti, pri čemu dominiraju točni i dosljedni odgovori modela. To se posebno odnosi na sljedeće modifikacije:

- Povećanje ili smanjenje visine - 97% uspješno
- Povećanje ili smanjenje određene površine ili baze - 92.5% uspješno
- Ogledanje (npr. "okreni naopako" ili "zrcali slijeva na desno") - 94% uspješno

Za ove transformacije model pokazuje visok stupanj dosljednosti i robusnosti, što upućuje da je za ove transformacije dovoljna jednostavna interpretacija.


S druge strane, kod određenih modifikacija zabilježen je veći udio neuspješnih rezultata:

- Povećanje ili smanjenje broja koordinata - 28% neuspješno
- Orijentacija prema zadanoj osi ili ravnini (npr. paralelno s XY-ravninom) - 20% neuspješno
- Povećanje ili smanjenje radijusa (npr. "smanji polumjer kruga") - 17% neuspješno

Ovi rezultati ukazuju na to da model teže interpretira ove vrste zahtjeva, što može biti posljedica dvosmislenosti u formulaciji upita ili veće apstraktne složenosti samih transformacija. Također, moguće je da bi dodatno treniranje modela na ovim tipovima zadataka poboljšalo njegovu preciznost i pouzdanost.

4.7.2. Jednostavni 2D oblici

Provedena je zasebna analiza nad skupom jednostavnih dvodimenzionalnih oblika. Popis svih testiranih oblika nalazi se u odjeljku 4.5. U ovoj skupini analizirani su sljedeći oblici: krug, trokut, peterokut. Na slici 4.9. prikazan je omjer ocjena za svaki od modifikacijskih zahtjeva primijenjenih na ove oblike.



Slika 4.9. Omjer ocjena za svaki modifikacijski upit — jednostavni 2D oblici

Najuspješnije modifikacije u ovoj skupini bile su sljedeće:

- Povećanje ili smanjenje broja koordinata - 100% uspješno
- Povratak na prethodnu verziju - 100% uspješno
- Povećanje ili smanjenje visine - 100% uspješno
- Orijentacija prema zadanoj osi ili ravnini (npr. paralelno s XY-ravninom) - 95% uspješno

Najnižu stopu uspjeha imaju:

- Povećanje ili smanjenje samo jedne strane tako da postane duža od ostalih - 72.5% uspješnih, 17.5% prosječnih i 10% neuspješnih
- Povećanje ili smanjenje određene površine ili baze - 80% uspješnih, 15% prosječnih i 5% neuspješnih

Sveukupno, sve analizirane modifikacije ostvarile su relativno visoku razinu uspješnosti, s najmanje 72.5% točnih odgovora. Modifikacije koje podrazumijevaju promjene veličine (npr. promjena radijusa ili broja koordinata) generalno su bile lakše za model, dok oni koji uključuju složeniju geometrijsku interpretaciju - poput promjene samo jedne strane ili baze - predstavljale veći izazov.

Primjer uspješnog testa - peterokut

Nakon pokretanja programa, na ekranu se ispisuje sljedeće:


Please input shape:

Korisnik unosi sljedeći upit:

Generate coordinates for a 2D pentagon

Model analizira upit te vraća sljedeći odgovor:

A 2D pentagon with its base parallel to the xz-plane can be represented by sampling points on a circle (using the unit circle for simplicity) at angles that divide the circle into five equal parts (72 degrees each). This results in the vertices of the pentagon. Using the decision tree, Rule 1 (polar equation for the unit circle and angle partitioning) was used to derive these coordinates.



Slika 4.10. Vizualizacija početne putanje peterokuta

Nakon prikaza rezultata, korisniku se nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik odlučuje modificirati oblik i upisuje sljedeći zahtjev:

Make the radius bigger

Model obrađuje zahtjev i generira novu verziju oblika. Odgovor modela glasi:

Scaled coordinates for a 2D pentagon with an increased radius (twice as large).



Slika 4.11. Povećani radijus peterokuta

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik zatim unosi sljedeći zahtjev:

Lengthen only one side so it is longer than the others

Model odgovara:

One side of the pentagon has been lengthened by moving the third vertex further along the z-axis.



Slika 4.12. Jedna stranica peterokuta produžena

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik zatim unosi sljedeći zahtjev:

Revert to the previous version

Model odgovara:

Restored the previous, symmetrical version of the enlarged pentagon.



Slika 4.13. Vraćena verzija prije produžetka stranice

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:

Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik prekida daljnju modifikaciju upisom naredbe:

quit

Model uspješno generira peterokut, nakon čega ispravno povećava njegov radijus i produžuje jednu stranicu, bez utjecaja na preostale. Nakon provedenih promjena, model je u mogućnosti vratiti prethodni skup koordinata — onaj prije produživanja stranice — čime potvrđuje mogućnost praćenja i vraćanja na ranije generirane verzije oblika.

Primjer neuspješnog testa - krug

Nakon pokretanja programa, na ekranu se ispisuje sljedeće:


Please input shape:

Korisnik unosi sljedeći upit:

Generate coordinates for a 2D circle

Model analizira upit te vraća sljedeći odgovor:

1. *I used Decision Tree Rule 1, where the circle's mathematical equation $x = \cos(t)$, $z = \sin(t)$ for t in $[0, 2)$ represents the circle in 2D with its base parallel to the xz -plane (y coordinates are zero here). Generated around 180 sample points to ensure a smooth circle. The first and last points are the same to close the circle.*



Slika 4.14. Vizualizacija početne putanje kruga

Nakon prikaza rezultata, korisniku se nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik odlučuje modificirati oblik i upisuje sljedeći zahtjev:

Make the radius smaller

Model obrađuje zahtjev i generira novu verziju oblika. Odgovor modela glasi:

*Generated a 2D circle with a smaller radius of 0.5, oriented parallel to the xz-plane. Utilized parametric equations: $x = 0.5 * \cos(t)$, $z = 0.5 * \sin(t)$ for t in $[0, 2)$, sampled at 180 points.*



Slika 4.15. Smanjen radijus kruga

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik zatim unosi sljedeći zahtjev:

Reduce the number of coordinates

Model odgovara:

Circle with fewer points, sampled uniformly using sin and cos functions, 20 points to describe a smaller circle on the xz-plane.



Slika 4.16. Krug sa smanjenim brojem koordinata

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik zatim unosi sljedeći zahtjev:

Orient it parallel to the XY-plane

Model odgovara:

Circle is now oriented parallel to the xy-plane with the same reduced number of 21 points and radius 0.5, using sine and cosine for point generation.



Slika 4.17. Krug orijentiran paralelno sa xy osi

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:

Would you like to modify the shape? (Type your modification or 'quit' to exit)


Korisnik prekida daljnju modifikaciju upisom naredbe:

quit

Model u početku generira putanju koja ne odgovara obliku kruga i ne prati odgovor modela. Tijekom kasnijih modifikacija, oblik putanje se značajno mijenja i postaje znatno sličniji traženom krugu. Međutim, test se svejedno smatra neuspješnim jer model ne prati korisničke zahtjeve na konzistentan način te izostaje kontinuitet u generiranju odgovora.

4.7.3. Jednostavni 3D oblici

Provedena je zasebna analiza nad skupom jednostavnih trodimenzionalnih oblika. Popis svih testiranih oblika nalazi se u odjeljku 4.5. U ovoj skupini analizirani su sljedeći oblici: kocka, piramida i šesterokutna prizma. Na slici 4.18. prikazan je omjer ocjena za svaki od modifikacijskih zahtjeva primijenjenih na ove oblike.



Slika 4.18. Omjer ocjena za svaki modifikacijski upit — jednostavni 3D oblici

Sve analizirane modifikacije pokazuju izrazito visok udio uspješno izvršenih operacija, pri čemu nijedna ne prelazi 12.5% neuspješnih odgovora.

Najuspješnije modifikacije uključuju:

- Povratak na prethodnu verziju - 100% uspješnosti

- Povećanje ili smanjenje određene površine ili baze - 100% uspješnosti
- Povećanje ili smanjenje visine - 95% uspješnosti
- Povećanje ili smanjenje samo jedne strane tako da postane duža od ostalih - 95% uspješnosti

Zaključno, model pokazuje visoku razinu pouzdanosti pri izvršavanju modifikacija nad jednostavnim 3D oblicima, osobito u slučaju promjena veličine i površina. Najveći izazov predstavlja rotacija objekta, što sugerira da bi dodatno treniranje modela na primjerima takvih transformacija moglo poboljšati njegovu točnost u tim slučajevima.

Primjer uspješnog testa - šesterokutna prizma

Nakon pokretanja programa, na ekranu se ispisuje sljedeće:


Please input shape:

Korisnik unosi sljedeći upit:

Generate coordinates for a 3D hexagonal prism

Model analizira upit te vraća sljedeći odgovor:

I used rule 2 from the decision tree to create points for the hexagonal prism by considering the base as a hexagon parallel to the xy-plane and extending these points along the z-axis to form the prism structure.



Slika 4.19. Vizualizacija početne putanje šesterokutne prizme

Nakon prikaza rezultata, korisniku se nudi mogućnost daljnje interakcije s modelom

putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik odlučuje modificirati oblik i upisuje sljedeći zahtjev:

Enlarge the base

Model obrađuje zahtjev i generira novu verziju oblika. Odgovor modela glasi:

These coordinates form an enlarged hexagonal prism with the base hexagon scaled up by a factor of 2.



Slika 4.20. Povećana baza šesterokutne prizme

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik zatim unosi sljedeći zahtjev:

Rotate 90 degrees about the X-axis

Model odgovara:

These coordinates form a hexagonal prism rotated 90 degrees about the X-axis.



Slika 4.21. Šesterokutna prizma rotirana po x osi

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik zatim unosi sljedeći zahtjev:

Revert to the previous version

Model odgovara:

These are the coordinates for the original unrotated expanded hexagonal prism.



Slika 4.22. Vraćena verzija prije rotacije

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:

Would you like to modify the shape? (Type your modification or 'quit' to exit)


Korisnik prekida daljnju modifikaciju upisom naredbe:

quit

Model uspješno generira šesterokutnu prizmu, povećava površinu baze te rotira objekt oko x-osi, pritom ne mijenjajući ostale značajke oblika. Također, ispravno vraća prizmu u stanje u kojem je bila prije primjene rotacije.

4.7.4. Složeni 2D oblici

Provedena je zasebna analiza nad skupom složenih dvodimenzionalnih oblika. Popis svih testiranih oblika nalazi se u odjeljku 4.5. U ovoj skupini analizirani su sljedeći oblici: oval, strelica i zvijezda. Na slici 4.23. prikazan je omjer ocjena za svaki od modifikacijskih zahtjeva primijenjenih na ove oblike.



Slika 4.23. Omjer ocjena za svaki modifikacijski upit — složeni 2D oblici

Najuspješniji modifikacijski zahtjevi bili su sljedeći:

- Povećanje ili smanjenje određene površine ili baze - 90% uspješnosti
- Ogledanje (npr. "okreni naopako" ili "zrcali slijeva na desno") - 100% uspješnosti

Najnižu stopu uspješnosti imali su sljedeći zahtjevi:

- Povećanje ili smanjenje broja koordinata - 45% uspješnosti, 20% prosječnih i 35% neuspješnih

- Orijentacija prema zadanoj osi ili ravnini (npr. paralelno s XY-ravninom) - 65% uspješnosti i 35% neuspješnosti

Rezultati ukazuju na to da složeni 2D oblici predstavljaju veći izazov za model prilikom interpretacije modifikacijskih zahtjeva u odnosu na jednostavne oblike. Poteškoće su osobito izražene kod geometrijskih promjena koje zahtijevaju promjenu broja koordinata ili orijentacije. Nasuprot tome, transformacije koje uključuju simetriju i proporcionalne promjene veličine model rješava vrlo pouzdano, dok složenije geometrijske promjene zahtijevaju dodatno usmjeravanje i preciznije formulisane upute.

Primjer uspješnog testa - strelica

Nakon pokretanja programa, na ekranu se ispisuje sljedeće:


Please input shape:

Korisnik unosi sljedeći upit:

Generate coordinates for a 2D arrow

Model analizira upit te vraća sljedeći odgovor:

To create a 2D arrow shape orientated parallel to the xz-plane, we define coordinates that form a basic arrow shape with a pointed head. The chosen coordinates outline a simple arrow starting at (0,0), forming the shaft of the arrow, and then extending to a pointed tip before closing the shape back at the starting point.



Slika 4.24. Vizualizacija početne putanje strelice

Nakon prikaza rezultata, korisniku se nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik odlučuje modificirati oblik i upisuje sljedeći zahtjev:

Flip it left to right

Model obrađuje zahtjev i generira novu verziju oblika. Odgovor modela glasi:

Here are the flipped coordinates for the 2D arrow, left to right, parallel to the xz -plane.



Slika 4.25. Oblik strelice nakon ogledanja

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik zatim unosi sljedeći zahtjev:

Rotate it 90 degrees

Model odgovara:

Here are the coordinates for the arrow shape oriented vertically (y -direction), parallel to the xz -plane.



Slika 4.26. Strelica nakon primjene rotacije

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik zatim unosi sljedeći zahtjev:

Increase the number of coordinates

Model odgovara:

The cylinder is rotated 90 degrees about the X-axis, so previous X aThe 2D arrow is further detailed by adding more points along the arrow shaft and head, while maintaining its overall structure, oriented vertically.



Slika 4.27. Strelica sa povećanim brojem koordinata

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:

Would you like to modify the shape? (Type your modification or 'quit' to exit)


Korisnik prekida daljnju modifikaciju upisom naredbe:

quit

Model uspješno generira putanju koja prikazuje jednostavni oblik strelice. Ispravno primjenjuje transformacije ogledanja i rotacije, a povećanje broja koordinata provodi bez narušavanja izvornog oblika.

4.7.5. Složeni 3D oblici

Provedena je zasebna analiza nad skupom složenih trodimenzionalnih oblika. Popis svih testiranih oblika nalazi se u odjeljku 4.5. U ovoj skupini analizirani su sljedeći oblici: stožac, oktaedar i cilindar. Na slici 4.28. prikazan je omjer ocjena za svaki od modifikacijskih zahtjeva primijenjenih na ove oblike.



Slika 4.28. Omjer ocjena za svaki modifikacijski upit — složeni 3D oblici

Najuspješniji modifikacijski zahtjevi:

- Povećanje ili smanjenje radijusa (npr. "smanji polumjer kruga") - 92.5% uspješnosti
- Povratak na prethodnu verziju - 85% uspješnosti
- Povećanje ili smanjenje visine - 97.5% uspješnosti

Najmanje uspješni zahtjevi:

- Rotacija za 90 stupnjeva u određenom smjeru - 30% neuspješnosti
- Povećanje ili smanjenje samo jedne strane tako da postane duža od ostalih - 15% neuspješnosti
- Orijentacija prema zadanoj osi ili ravnini (npr. paralelno s XY-ravninom) - 60% uspješnosti, 35% neuspješnosti

Složeniji trodimenzionalni oblici uvođe dodatne izazove prilikom modifikacija. Promjene koje se odnose na veličinu (visine ili radijusa) su uspješno izvršene i kod složenijih trodimenzionalnih oblika. No, model ima značajnih poteškoća kod modifikacija koje zahtijevaju rotacije ili selektivno mijenjanje pojedinih strana, što upućuje na potrebu za dodatnim usmjeravanjem modela kod kompleksnijih prostornih transformacija.

Primjer uspješnog testa - cilindar

Nakon pokretanja programa, na ekranu se ispisuje sljedeće:


Please input shape:

Korisnik unosi sljedeći upit:

Generate coordinates for a 3D cylinder

Model analizira upit te vraća sljedeći odgovor:

I used decision tree rule 2 by defining two parallel circular bases along the z-axis and connecting corresponding points on these circles to form the cylinder.



Slika 4.29. Vizualizacija početne putanje cilindra

Nakon prikaza rezultata, korisniku se nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik odlučuje modificirati oblik i upisuje sljedeći zahtjev:

Make the radius of base smaller

Model obrađuje zahtjev i generira novu verziju oblika. Odgovor modela glasi:

The coordinates for a 3D cylinder with a smaller base and a height of 5 units, oriented parallel to the z-axis, are provided. A radius of 0.5 units is used for the circular bases.



Slika 4.30. Povećan radijus baze cilindra

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik zatim unosi sljedeći zahtjev:

Reduce the height

Model odgovara:

The height of the cylinder is now reduced to 3 units, maintaining the smaller base geometry.



Slika 4.31. Smanjena visina cilindra

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik zatim unosi sljedeći zahtjev:

Rotate 90 degrees about the X-axis

Model odgovara:

The cylinder is rotated 90 degrees about the X-axis, so previous X and Z coordinates become new X and Y coordinates respectively.



Slika 4.32. Cilindar rotiran po x osi

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:

Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik prekida daljnju modifikaciju upisom naredbe:

quit

Model uspješno generira jednostavni oblik cilindra te ispravno provodi modifikacije, pritom ne mijenjajući ostale značajke oblika.

Primjer neuspješnog testa - oktaedar

Nakon pokretanja programa, na ekranu se ispisiuje sljedeće:


Please input shape:

Korisnik unosi sljedeći upit:

Generate coordinates for a 3D octahedron

Model analizira upit te vraća sljedeći odgovor:

The 3D octahedron is a polyhedron that can be represented by its vertices and edges. The coordinates above represent vertices of one possible octahedron centered at the origin. The structure consists of two pyramids sharing a common base and is symmetric across all three coordinate axes, its faces are equilateral triangles.



Slika 4.33. Vizualizacija početne putanje oktaedra

Nakon prikaza rezultata, korisniku se nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik odlučuje modificirati oblik i upisuje sljedeći zahtjev:

Orient its base parallel to the XY-plane

Model obrađuje zahtjev i generira novu verziju oblika. Odgovor modela glasi:

The coordinates provided represent a 3D octahedron with its base parallel to the XY-plane. These vertices form a symmetric structure around the origin with a central base at $z=0$.



Slika 4.34. Baza oktaedra postavljena paralelno sa xy osi

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik zatim unosi sljedeći zahtjev:

Lengthen only one side so it is longer than the others

Model odgovara:

The octahedron has been modified to have one edge longer by increasing the x-coordinate of the first vertex from 1.0 to 1.5 while keeping other vertices the same.



Slika 4.35. Jedna strana oktaedra povećana

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik zatim unosi sljedeći zahtjev:

Revert to the previous version

Model odgovara:

Reverted the coordinates of the 3D octahedron to its base version such that its base is parallel to the XY-plane.



Slika 4.36. Vraćena verzija prije povećanja stranice

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:

Would you like to modify the shape? (Type your modification or 'quit' to exit)


Korisnik prekida daljnju modifikaciju upisom naredbe:

quit

Model generira putanju koja predstavlja vrlo pojednostavljenu verziju traženog oblika, no nakon primjene modifikacija željeni se oblik u potpunosti gubi.

4.7.6. Kompleksni 2D oblici

Provedena je zasebna analiza nad skupom kompleksnih dvodimenzionalnih oblika. Popis svih testiranih oblika nalazi se u odjeljku 4.5. U ovoj skupini analizirani su sljedeći oblici: sinusoidu, cvijet i oblik mladog mjeseca. Na slici 4.37. prikazan je omjer ocjena za svaki od modifikacijskih zahtjeva primijenjenih na ove oblike.



Slika 4.37. Omjer ocjena za svaki modifikacijski upit — kompleksni 2D oblici

Najuspješniji zahtjevi:

- Ogledanje (npr. "okreni naopako" ili "zrcali slijeva na desno") - 97.5% uspješnosti

Najmanje uspješni zahtjevi:

- Povećanje ili smanjenje radijusa (npr. "smanji polumjer kruga") - 45% uspješnosti, 55%, neuspješnosti

- Povećanje ili smanjenje broja koordinata - 55% uspješnosti i 35% neuspješnosti

Kod kompleksnih dvodimenzionalnih oblika model se suočava s povećanim izazovima u generiranju traženih modifikacija koje uključuju kvantitativne promjene, poput smanjenja broja koordinata. Do netočnih rezultata možemo pretpostaviti da dolazi zbog potrebe za dodatnim razumijevanjem strukture oblika kompleksnih dvodimenzionalnih oblika. S druge strane, transformacije koje imaju jasniju vizualnu reprezentaciju, poput ogledanja, pokazale su stabilne i vrlo točne rezultate. To ukazuje na potencijalnu potrebu za dodatnim usmjeravanjem modela kada se radi o numeričkim transformacijama, dok su simetrične, vizualno intuitivne promjene već dobro usvojene.

Primjer uspješnog testa - sinusoida

Nakon pokretanja programa, na ekranu se ispisuje sljedeće:


Please input shape:

Korisnik unosi sljedeći upit:

Generate coordinates for a 2D sine wave

Model analizira upit te vraća sljedeći odgovor:

Coordinates for a 2D sine wave parallel to the xz-plane have been generated using a sine function. The shape is not closed as it represents a continuous wave.



Slika 4.38. Vizualizacija početne putanje sinusoide

Nakon prikaza rezultata, korisniku se nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik odlučuje modificirati oblik i upisuje sljedeći zahtjev:

Increase the number of coordinates

Model obrađuje zahtjev i generira novu verziju oblika. Odgovor modela glasi:

Increased points for a 2D sine wave to cover a complete oscillation more smoothly along the xz-plane.



Slika 4.39. Sinusoida sa povećanim brojem koordinata

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik zatim unosi sljedeći zahtjev:

Flip it upside down

Model odgovara:

The coordinates are inverted along the y-direction to create a 2D sine wave flipped upside down, parallel to the xz-plane.



Slika 4.40. Sinusoida reflektirana oko horizontalne osi

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:

Would you like to modify the shape? (Type your modification or 'quit' to exit)


Korisnik zatim unosi sljedeći zahtjev:

Orient it parallel to the YZ-plane

Model odgovara:

Matched the specification for an inverted sine wave aligned along the yz-plane.

Origin shifted to $x=0$.



Slika 4.41. Sinusoida orijentirana paralelno sa yz ravninom

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:

Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik prekida daljnju modifikaciju upisom naredbe:

quit

Model uspješno generira putanju traženog oblika te bez poteškoća provodi sve zadane transformacije nad njim.

Primjer neuspješnog testa - cvijet

Nakon pokretanja programa, na ekranu se ispisuje sljedeće:


Please input shape:

Korisnik unosi sljedeći upit:

Generate coordinates for a 2D flower with circle-arcs as petals

Model analizira upit te vraća sljedeći odgovor:

The flower shape is 2D, oriented parallel to the xz-plane. The shape consists of symmetric circular arcs forming the petals.



Slika 4.42. Vizualizacija početne putanje cvijeta

Nakon prikaza rezultata, korisniku se nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik odlučuje modificirati oblik i upisuje sljedeći zahtjev:

Increase the number of coordinates

Model obrađuje zahtjev i generira novu verziju oblika. Odgovor modela glasi:

Here's a more detailed set of coordinates forming the 2D flower with circular-arc petals.



Slika 4.43. Cvijet sa povećanim brojem koordinata

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik zatim unosi sljedeći zahtjev:

Orient it parallel to the XY-plane

Model odgovara:

The flower orientation has been corrected to be parallel to the XY-plane.



Slika 4.44. Cvijet orijentiran paralelno sa xy ravninom

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:


Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik zatim unosi sljedeći zahtjev:

Revert to the previous version

Model odgovara:

The coordinates describe a detailed 2D flower with circular arcs as petals, oriented parallel to the xz-plane.



Slika 4.45. Vraćena verzija prije orijentiranja sa xy ravninom

Korisniku se ponovno nudi mogućnost daljnje interakcije s modelom putem poruke:

Would you like to modify the shape? (Type your modification or 'quit' to exit)

Korisnik prekida daljnju modifikaciju upisom naredbe:

quit

Model ne uspijeva generirati putanju traženog oblika. Tijekom primjene modifikacija vidljiv je određeni napredak prema željenom obliku, no on se na kraju gubi, zbog čega se scenarij ne može smatrati uspješnim.

5. Zaključak

Integracijom robotike s velikim jezičnim modelima (LLM-ova), poput ChatGPT-a, otvaraju se nove mogućnosti u području inteligentnog upravljanja, interakcije s ljudima i razumijevanja konteksta zadatka. Uz pomoć umjetne inteligencije, roboti mogu u stvarnom vremenu prikupljati podatke, analizirati situacije i donositi odgovarajuće odluke, čime se znatno povećava njihova autonomija i učinkovitost.

Tijekom provedbe rada uočeno je da složenost traženog oblika izravno utječe na zahtjeve u pisanju prompta. Što je zadani oblik složeniji, to prompt mora biti precizniji i detaljniji. Složeni oblici zahtijevaju predstavljaju veću apstrakciju i zahtijevaju jasnije definirane značajke (poput zakrivljenosti, simetrije, zatvorenosti), kako bi model mogao generirati točnu i prepoznatljivu putanju.

Veliki jezični modeli (LLM-ovi) pokazuju izniman potencijal za omogućavanje razumijevanja i interpretacije konteksta kod robota. Njihovom primjenom moguće je razviti sustave koji ne samo da odgovaraju na upite, već i samostalno zaključuju, planiraju sljedeće korake i vode dijalog prirodnim jezikom — čime se znatno približavamo ideji robota kao autonomnog, inteligentnog suradnika.

Literatura

- [1] Nina. (2025) Github repo. Pristupano: 2025-06-10. [Mrežno]. Adresa: <https://github.com/CognitoAgent/Path-generator-with-LLM.git>
- [2] OpenAI. (2025) Wikipedia. Pristupano: 2025-06-12. [Mrežno]. Adresa: <https://en.wikipedia.org/wiki/OpenAI>
- [3] ——. (2025) gpt-4o. Pristupano: 2025-06-12. [Mrežno]. Adresa: <https://platform.openai.com/docs/models/gpt-4o>
- [4] ——. (2025) Prompt engineering. Pristupano: 2025-06-12. [Mrežno]. Adresa: <https://platform.openai.com/docs/guides/text?api-mode=chat>
- [5] FileFormat.app. (2025) Json about. Pristupano: 2025-06-10. [Mrežno]. Adresa: <https://kb.fileformat.app/hr/extension/json-file-info/>
- [6] Google. (2025) Google drive. Pristupano: 2025-06-10. [Mrežno]. Adresa: <https://developers.google.com/workspace/drive/api/guides/about-sdk>
- [7] ——. (2025) Google sheets. Pristupano: 2025-06-10. [Mrežno]. Adresa: <https://developers.google.com/workspace/sheets/api/guides/concepts>

Sažetak

Generiranje putanja mobilnog robota putem velikih jezičnih modela

Nina Karavanić

U radu je razvijen sustav koji omogućuje zadavanje putanje bespilotnoj letjelici korištenjem prirodnog jezika, uz primjenu velikih jezičnih modela (LLM-ova) poput ChatGPT-a. Cilj sustava bio je omogućiti korisniku da jednostavnim tekstualnim upitom zatraži generiranje koordinata koje prikazuju željeni 2D ili 3D geometrijski oblik. Kroz definiranu strukturu poruka i tehnike promptnog inženjerstva, model se usmjerava da točno interpretira zahtjev i generira ispravnu putanju. Rezultati, uključujući slike i poruke s objašnjenjima, automatski se pohranjuju u Google Drive i Google Sheets za potrebe analize. Poseban naglasak stavljen je na složenost upita: složeniji oblici zahtijevaju preciznije i detaljnije upute. Rezultati pokazuju da sustav može učinkovito generirati jednostavne putanje u dvodimenzionalnom i trodimenzionalnom svijetu.

Ključne riječi: robotika; veliki jezični model; planiranje putanje

Abstract

Generating mobile robot paths using large language models

Nina Karavanić

In this thesis, a system is developed that allows the user to specify a path for an unmanned aerial vehicle using natural language, utilising large language models (LLMs) such as ChatGPT. The aim of the system was to allow the user to request the generation of coordinates representing the desired 2D or 3D geometric shape with a simple text query. Through a defined message structure and prompt engineering techniques, the model is guided to accurately interpret the request and generate the correct trajectory. The results, including images and explanatory messages, are automatically stored in Google Drive and Google Sheets for analysis. Special attention is paid to the complexity of the query, more complex shapes require more precise and detailed instructions. The results show that the system can efficiently generate simple paths in both the two-dimensional and three-dimensional world.

Keywords: robotics; large language model; path planning